UNIVERSIDADE ESTADUAL DE GOIÁS
CÂMPUS METROPOLITANO
UNIDADE UNIVERSITÁRIA DE TRINDADE
CURSO DE SISTEMAS DE INFORMAÇÃO

JOÃO MANOEL SILVA MORAIS
HAYYRA EDUARDA ROCHA
RUAN SILVA CARVALHO
PEDRO LUCAS HIPÓLITO DE OLIVEIRA

# ESTIMATIVA DA TAXA DE APROVAÇÃO DOS ANOS FINAIS DO ENSINO FUNDAMENTAL EM GOIÁS:
## uma proposta baseada em árvore de decisão para regressão

TRINDADE-GO
2026

JOÃO MANOEL SILVA MORAIS
HAYYRA EDUARDA ROCHA
RUAN SILVA CARVALHO
PEDRO LUCAS HIPÓLITO DE OLIVEIRA

# ESTIMATIVA DA TAXA DE APROVAÇÃO DOS ANOS FINAIS DO ENSINO FUNDAMENTAL EM GOIÁS:
## uma proposta baseada em árvore de decisão para regressão

Projeto Integrador apresentado à disciplina de Inteligência Artificial do Curso de Sistemas de Informação da Universidade Estadual de Goiás, Câmpus Metropolitano, Unidade Universitária de Trindade, como requisito parcial de avaliação do semestre 2026/2, sob orientação do professor Rafael Viana.

TRINDADE-GO
2026

**SUMÁRIO**


**1 INTRODUÇÃO E CONTEXTUALIZAÇÃO.....4**
**2 OBJETIVO DA SOLUÇÃO.....5**
**3 ANÁLISE DA BASE DE DADOS.....6**
3.1 ORIGEM E FINALIDADE DOS DADOS.....6
3.2 QUANTIDADE DE REGISTROS E PRINCIPAIS ATRIBUTOS.....6
3.3 ATRIBUTOS QUE PODERIAM SER UTILIZADOS COMO ENTRADAS.....6
3.4 VARIÁVEL-ALVO.....7
3.5 PROBLEMAS DE QUALIDADE, DISPONIBILIDADE E INTERPRETAÇÃO.....7
**4 COMPARAÇÃO DAS TÉCNICAS DE IA.....9**
4.1 REGRESSÃO LINEAR MÚLTIPLA.....9
4.2 ÁRVORE DE DECISÃO PARA REGRESSÃO.....9
**5 JUSTIFICATIVA DA TÉCNICA SELECIONADA.....10**
**6 DESCRIÇÃO DA SOLUÇÃO PROPOSTA.....11**
6.1 REPRESENTAÇÃO GRÁFICA DA SOLUÇÃO.....11
6.2 DADOS UTILIZADOS COMO ENTRADA.....11
6.3 ETAPAS DE PREPARAÇÃO E UTILIZAÇÃO DOS DADOS.....12
6.4 FUNCIONAMENTO GERAL DA TÉCNICA.....12
6.5 RESULTADO PRODUZIDO E INTERPRETAÇÃO DAS ESTIMATIVAS.....12
6.6 APOIO ÀS DECISÕES.....13
**7 PROPOSTA DE AVALIAÇÃO E ANÁLISE CRÍTICA.....14**
7.1 MÉTRICAS E CRITÉRIOS DE AVALIAÇÃO.....14
7.2 POSSÍVEIS ERROS E SUAS CONSEQUÊNCIAS.....14
7.3 LIMITAÇÕES DA BASE DE DADOS E DA TÉCNICA ESCOLHIDA.....14
7.4 DIFICULDADES NA APLICAÇÃO PRÁTICA.....15
7.5 CUIDADOS NA INTERPRETAÇÃO DOS RESULTADOS.....15
7.6 POSSIBILIDADES DE MELHORIA OU CONTINUIDADE DA PROPOSTA.....15
7.7 RESPOSTA À QUESTÃO PARA REFLEXÃO.....16
**8 CONSIDERAÇÕES FINAIS.....17**
**REFERÊNCIAS.....18**

# 1 INTRODUÇÃO E CONTEXTUALIZAÇÃO

A taxa de aprovação é um dos indicadores de rendimento mais usados para acompanhar escolas e orientar a gestão educacional. Ela compõe, junto com o desempenho em avaliações, o Índice de Desenvolvimento da Educação Básica (Ideb) e é publicada anualmente pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) a partir do Censo Escolar.

Os anos finais do Ensino Fundamental (6º ao 9º ano) são uma etapa sensível. É nela que se concentram reprovação e abandono no Brasil, por causa da troca de professor único por vários professores, da mudança de escola e da entrada na adolescência.

Este trabalho analisa uma base de 1.742 escolas de Goiás, de 246 municípios, com características institucionais e taxas de aprovação de 2025. A pergunta que orienta o trabalho é: **como usar essas características e os demais indicadores disponíveis para estimar a taxa de aprovação dos anos finais do Ensino Fundamental?**

Esse problema pode ser abordado por técnicas de Inteligência Artificial (IA), em especial pelo aprendizado de máquina supervisionado, que aprende com exemplos já conhecidos a relação entre as características das escolas e a taxa de aprovação. Uma estimativa desse tipo pode apoiar decisões como:

a) identificar escolas cuja taxa real ficou bem abaixo do que seria esperado para escolas com perfil parecido;
b) priorizar visitas técnicas, formação de professores e programas de reforço;
c) estimar a taxa em escolas ou anos em que o dado ainda não foi consolidado.

## 2 OBJETIVO DA SOLUÇÃO

O objetivo é construir um modelo de **regressão** que receba as características de uma escola e devolva uma estimativa numérica, entre 0 e 100, da sua taxa de aprovação nos anos finais do Ensino Fundamental. A solução é definida da seguinte forma:

a) **entrada:** dependência administrativa, localização, município e as taxas de aprovação das outras etapas, quando a escola as oferece;
b) **saída:** a taxa de aprovação estimada (aprovacao_anos_finais_pct), acompanhada do erro esperado;
c) **uso:** comparar a taxa real com a estimada; uma escola com taxa real muito abaixo da estimada é um sinal de alerta que merece investigação pela gestão.

A solução é uma ferramenta de **apoio** à decisão. Ela aponta onde olhar, mas não explica por que uma escola tem rendimento alto ou baixo nem substitui o acompanhamento pedagógico.

# 3 ANÁLISE DA BASE DE DADOS

A base tem 1.742 escolas de 246 municípios goianos, todas com a taxa de aprovação dos anos finais preenchida, mas com cerca de metade das demais taxas vazia. A variável-alvo é muito concentrada perto de 100%, o que constitui o principal desafio para o modelo.

## 3.1 ORIGEM E FINALIDADE DOS DADOS

Os dados são do ano de 2025 e seguem o formato dos Indicadores de Rendimento Escolar publicados pelo INEP a partir do Censo Escolar. Sua finalidade original é o acompanhamento do fluxo escolar (aprovação, reprovação e abandono) por escola. O arquivo recebido estava em PDF, com colunas quebradas entre páginas e nomes de escolas cortados; para a análise, ele foi reconstruído como tabela (CSV) com 1.742 linhas.

## 3.2 QUANTIDADE DE REGISTROS E PRINCIPAIS ATRIBUTOS

A base possui 1.742 registros, um por escola, distribuídos em 246 municípios, e 10 atributos. O Quadro 1 apresenta cada atributo, seu tipo e o papel que terá na solução proposta.

**Quadro 1 –** Atributos da base de dados

| **Atributo** | **Tipo** | **Papel na solução** |
|---|---|---|
| ano | inteiro (sempre 2025) | descartado: não varia |
| codigo_municipio, municipio | categórico, 246 valores | entrada, agrupada ou codificada |
| codigo_escola, escola | identificadores únicos | descartados: não generalizam |
| localizacao | Urbana (1.537) / Rural (205) | entrada |
| dependencia_administrativa | Estadual (837), Municipal (456), Privada (448), Federal (1) | entrada |
| aprovacao_anos_iniciais_pct | numérico, 0 a 100 | entrada; 51% vazio |
| aprovacao_ensino_medio_pct | numérico, 0 a 100 | entrada; 47% vazio |
| aprovacao_anos_finais_pct | numérico, 0 a 100 | variável-alvo; sem valores vazios |

Fonte: Elaborado pelos autores (2026), com dados da base 02_educacao.

## 3.3 ATRIBUTOS QUE PODERIAM SER UTILIZADOS COMO ENTRADAS

Foram selecionados como entradas os atributos que descrevem a escola e que estariam disponíveis no momento da estimativa:

a) **dependência administrativa:** é o atributo que mais separa as escolas com aprovação baixa: as municipais somam 96 das 142 escolas abaixo de 95%;

b) **localização (urbana ou rural):** quase não altera a média (98,7% nas rurais e 98,5% nas urbanas), mas é mantida porque representa contextos diferentes e permite verificar se o modelo erra mais em algum deles;
c) **taxa de aprovação dos anos iniciais:** é a entrada mais informativa; entre as escolas que têm os dois dados, sua correlação com a taxa dos anos finais é de 0,58;
d) **taxa de aprovação do ensino médio:** traz informação complementar, com correlação de apenas 0,22 com a taxa dos anos finais;
e) **indicadores de etapa oferecida (criados a partir da base):** marcam se a escola oferece anos iniciais e ensino médio, para que a ausência dessas taxas seja usada como informação;
f) **município, de forma agregada:** representa o contexto local, mas é usado agrupado (por exemplo, pelo número de escolas do município ou pela região), porque 246 categorias com poucas escolas cada levariam o modelo a decorar municípios.

Foram descartados o ano, que é sempre 2025, e o código e o nome da escola e do município, que apenas identificam registros e não ajudam a estimar a taxa de outras escolas.

## 3.4 VARIÁVEL-ALVO

A variável-alvo é a taxa de aprovação dos anos finais do Ensino Fundamental (aprovacao_anos_finais_pct), um valor numérico contínuo entre 0 e 100 e preenchido para todas as escolas. Por ser numérica, o problema é de regressão. A média é 98,5% e a mediana é 100%. Apenas 142 escolas (8%) ficam abaixo de 95%, e são justamente elas que mais interessam à gestão. A rede municipal concentra 96 dessas 142 escolas.

## 3.5 PROBLEMAS DE QUALIDADE, DISPONIBILIDADE E INTERPRETAÇÃO

Foram identificados os seguintes problemas na base:

a) **ausência estrutural, não aleatória:** a falta de dado reflete a oferta da escola; 420 das 456 municipais têm taxa dos anos iniciais e 663 das 837 estaduais têm taxa do ensino médio. Preencher esses vazios com a média criaria escolas que não existem, por isso a ausência deve ser tratada como informação;
b) **escolas sem nenhuma outra taxa:** para 215 escolas, o modelo só conta com rede, localização e município;
c) **efeito teto:** com 53% dos valores exatamente em 100%, um modelo que sempre responde cerca de 99% parece bom na média, mas erra justamente nas escolas críticas;

d) **valores suspeitos:** uma escola privada de Goiânia tem 0% nos anos finais e outra tem 0% nos anos iniciais; são prováveis erros de registro e devem ser revisados ou retirados;
e) **falta do tamanho da escola:** sem número de matrículas, não é possível saber se 90% significa 2 reprovações em 20 alunos ou 50 em 500, e escolas pequenas oscilam muito;
f) **poucos fatores explicativos:** não há nível socioeconômico, infraestrutura, formação docente, abandono, distorção idade-série nem notas do Sistema de Avaliação da Educação Básica (Saeb);
g) **um só ano:** sem histórico, não é possível usar a taxa do ano anterior, que tende a ser o melhor previsor;
h) **categorias desequilibradas:** há uma única escola federal, e Goiânia sozinha tem 305 escolas, enquanto muitos municípios têm de 1 a 3.

# 4 COMPARAÇÃO DAS TÉCNICAS DE IA

Como a saída é um número contínuo, o problema é de **aprendizado supervisionado por regressão**. Foram comparadas duas técnicas estudadas na disciplina. Para cada uma são apresentados o princípio de funcionamento, a forma de aplicação ao problema e as principais vantagens e limitações nesse contexto.

## 4.1 REGRESSÃO LINEAR MÚLTIPLA

**Princípio.** Ajusta uma equação em que a saída é uma soma ponderada das entradas, escolhendo os pesos que minimizam o erro quadrático, conforme a Equação 1.

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_n x_n \quad (1)$$

**Aplicação.** A rede e a localização viram variáveis indicadoras (0 ou 1), e as taxas das outras etapas entram como números, acompanhadas de um indicador de etapa não oferecida.

**Vantagens.** É simples, rápida e cada peso tem leitura direta (por exemplo, “ser municipal reduz a estimativa em X pontos”).

**Limitações.** Supõe relações lineares e aditivas, o que não combina com o efeito teto em 100%. Pode prever valores acima de 100, que precisam ser cortados.

## 4.2 ÁRVORE DE DECISÃO PARA REGRESSÃO

**Princípio.** Divide as escolas em grupos por perguntas sucessivas (“é municipal?”, “a aprovação nos anos iniciais é menor que 95%?”). Em cada divisão, escolhe a pergunta que mais reduz a variância da saída. A estimativa de uma escola é a média das escolas que caem na mesma folha.

**Aplicação.** As entradas são usadas quase sem preparação. A ausência de uma etapa vira um ramo próprio da árvore, que é exatamente o que a base pede.

**Vantagens.** Capta relações não lineares e interações (como “municipal *e* com anos iniciais baixos”). Não precisa de normalização e suas regras podem ser mostradas a um gestor.

**Limitações.** Uma árvore profunda decora os dados (sobreajuste) e muda muito com pequenas alterações na base. As estimativas são em degraus, uma por folha.

## 5 JUSTIFICATIVA DA TÉCNICA SELECIONADA

A técnica escolhida é a **árvore de decisão para regressão**. A escolha decorre diretamente das características da base:

a) **ausência estrutural:** metade das escolas não tem taxa dos anos iniciais ou do ensino médio porque não oferece a etapa; a árvore trata isso como um ramo (“não oferece anos iniciais”), sem inventar valores;

b) **efeito teto e não linearidade:** com 53% das escolas em 100%, a relação entre entradas e saída não é uma reta; a árvore estima por faixas e nunca passa de 100%, porque cada folha é uma média de taxas reais;

c) **interações:** a análise mostrou que o risco se concentra nas escolas municipais e, entre elas, pesa a aprovação nos anos iniciais; uma árvore representa esse “e” naturalmente, enquanto na regressão linear seria preciso criar o termo de interação manualmente;

d) **explicabilidade:** o resultado será usado por gestores, que precisam entender por que uma escola foi apontada; as regras da árvore podem ser lidas como frases, o que facilita a comunicação dos resultados;

e) **tamanho da base:** com cerca de 1.700 escolas, uma árvore com profundidade limitada é estável o bastante.

# 6 DESCRIÇÃO DA SOLUÇÃO PROPOSTA

A solução tem três fases: preparar os dados, treinar e validar a árvore, e usar a diferença entre a taxa real e a estimada para apontar escolas que merecem atenção.

## 6.1 REPRESENTAÇÃO GRÁFICA DA SOLUÇÃO

A Figura 1 apresenta o fluxograma com as principais etapas da solução, da base de dados até o apoio à gestão.

**Figura 1 –** Fluxograma da solução proposta




Fonte: Elaborado pelos autores (2026).

## 6.2 DADOS UTILIZADOS COMO ENTRADA

As entradas do modelo são:

a) dependência administrativa: Estadual, Municipal ou Privada (a única escola federal é agrupada com as estaduais ou retirada);
b) localização: Urbana ou Rural;
c) taxas de aprovação dos anos iniciais e do ensino médio, cada uma acompanhada de um indicador 0/1 de etapa oferecida;

d) município, representado de forma agregada (por exemplo, o número de escolas do município ou a região), porque 246 categorias com poucas escolas cada levariam a árvore a decorar municípios.

## 6.3 ETAPAS DE PREPARAÇÃO E UTILIZAÇÃO DOS DADOS

A preparação e a utilização dos dados seguem as etapas:

a) converter a base do PDF para CSV e conferir se as colunas ficaram alinhadas;
b) retirar ano, código e nome da escola, que não generalizam;
c) revisar os casos com 0%, que são provavelmente erros de registro;
d) codificar as categorias em variáveis 0/1 e criar os indicadores de etapa oferecida (a árvore não exige normalização);
e) separar 80% das escolas para treino e 20% para teste, mantendo a proporção de cada rede nos dois grupos;
f) treinar e validar o modelo com os dados de treino e medir o erro final nos dados de teste;
g) aplicar o modelo final a todas as escolas, a cada novo ano de dados, para obter as estimativas e os resíduos.

## 6.4 FUNCIONAMENTO GERAL DA TÉCNICA

A árvore começa com todas as escolas de treino e procura a pergunta que, ao dividir o grupo em dois, mais reduz a variância da taxa de aprovação (BREIMAN et al., 1984). Repete isso em cada subgrupo até atingir a profundidade máxima ou um número mínimo de escolas por folha (por exemplo, 30), o que evita folhas baseadas em poucas escolas.

Um caminho típico seria: “rede = municipal” → “aprovação nos anos iniciais < 95%” → estimativa = média das escolas dessa folha. A profundidade e o mínimo por folha são escolhidos por validação cruzada no conjunto de treino; o conjunto de teste só é usado no final.

## 6.5 RESULTADO PRODUZIDO E INTERPRETAÇÃO DAS ESTIMATIVAS

Para cada escola, o modelo devolve a taxa estimada e o **resíduo** (taxa real menos taxa estimada). A saída final é uma tabela com escola, município, rede, taxa real, taxa estimada e resíduo, ordenada do resíduo mais negativo para o mais positivo.

A estimativa deve ser interpretada como a taxa típica de escolas com perfil semelhante. Por exemplo, uma estimativa de 97,2% significa que escolas parecidas aprovaram, em média, 97,2% dos alunos nos anos finais; não é uma meta nem uma nota da escola. Toda estimativa vem

acompanhada do erro médio do modelo no teste: com erro de 1,5 ponto, uma diferença de 1 ponto entre a taxa real e a estimada não deve ser tratada como relevante.

## 6.6 APOIO ÀS DECISÕES

Os resultados apoiam a gestão da seguinte forma:

a) **resíduo muito negativo:** a escola aprova menos do que outras de perfil parecido e é candidata a visita técnica, formação docente ou reforço;
b) **resíduo muito positivo:** a escola aprova mais do que o esperado; pode ter práticas a compartilhar ou aprovação automática que merece verificação;
c) **regras da árvore:** mostram quais perfis concentram as taxas mais baixas, como a rede municipal com anos iniciais fracos, e ajudam a direcionar políticas para grupos de escolas.

# 7 PROPOSTA DE AVALIAÇÃO E ANÁLISE CRÍTICA

O modelo deve ser julgado pelo erro médio e também pelo erro nas escolas de aprovação baixa, porque um modelo que sempre responde 100% já tem erro médio pequeno nesta base e não serve para nada.

## 7.1 MÉTRICAS E CRITÉRIOS DE AVALIAÇÃO

As métricas propostas, e a justificativa de cada uma, são:

a) **erro absoluto médio (MAE):** quantos pontos percentuais o modelo erra, em média; é a métrica mais fácil de explicar a um gestor;
b) **raiz do erro quadrático médio (RMSE):** pune mais os erros grandes; como os casos importantes são as escolas que fogem do padrão, é tão relevante quanto o MAE;
c) **coeficiente de determinação ($R^2$):** fração da variação entre escolas que o modelo explica; o valor 0 equivale a sempre prever a média;
d) **MAE nas escolas abaixo de 95%:** mede o erro justamente no grupo que a gestão quer encontrar; é necessário porque, nesta base, um modelo que sempre responde 100% já teria MAE geral baixo sem apontar nenhuma escola crítica;
e) **erro por rede e por localização:** verifica se o modelo erra mais para algum grupo, como as escolas municipais.

## 7.2 POSSÍVEIS ERROS E SUAS CONSEQUÊNCIAS

Os erros possíveis têm pesos diferentes:

a) **superestimar uma escola com rendimento baixo:** a escola parece normal e deixa de receber apoio; é o erro mais grave;
b) **subestimar uma escola com rendimento alto:** a gestão gasta uma visita sem necessidade; é um custo menor;
c) **erro sistemático por grupo:** se o modelo erra mais nas rurais ou municipais, pode reforçar desigualdades na distribuição de recursos.

## 7.3 LIMITAÇÕES DA BASE DE DADOS E DA TÉCNICA ESCOLHIDA

As principais limitações são:

a) **da base:** um único ano, sem número de matrículas, sem fatores socioeconômicos, com ausência estrutural nas outras etapas e efeito teto;

b) **da técnica:** uma árvore é instável e estima por degraus; regras com poucas escolas por folha podem ser coincidência;
c) **de generalização:** o modelo aprende o padrão de Goiás em 2025 e não deve ser aplicado a outros estados ou anos sem novo treinamento.

## 7.4 DIFICULDADES NA APLICAÇÃO PRÁTICA

Na aplicação prática, podem surgir as seguintes dificuldades:

a) os dados de rendimento são consolidados pelo INEP com atraso, então as estimativas sempre se referem a um ano já encerrado;
b) a base veio em PDF e precisou ser convertida; em uso real, seria necessário um processo automático de obtenção e limpeza dos dados;
c) o modelo precisa ser retreinado a cada ano, porque políticas de avaliação e de fluxo escolar mudam e alteram o padrão das taxas;
d) gestores podem resistir a uma ferramenta automática se não entenderem como ela chega aos resultados, o que reforça a escolha de uma técnica interpretável.

## 7.5 CUIDADOS NA INTERPRETAÇÃO DOS RESULTADOS

Na interpretação, devem ser considerados os seguintes cuidados:

a) a aprovação pode subir por promoção automática ou flexibilização da avaliação, sem melhora real da aprendizagem; uma taxa alta não garante ensino de qualidade;
b) uma escola apontada como alerta deve ser investigada, não punida; o modelo indica onde olhar, e quem decide é a equipe pedagógica;
c) escolas pequenas podem cair em alerta por causa de poucos alunos; o ideal é cruzar o resíduo com o número de matrículas;
d) uma estimativa próxima da taxa real não significa que o modelo encontrou as causas do rendimento, como discutido na seção 7.7.

## 7.6 POSSIBILIDADES DE MELHORIA OU CONTINUIDADE DA PROPOSTA

A proposta pode ser continuada com:

a) inclusão de série histórica (taxa do ano anterior), matrículas, abandono, distorção idade-série, Saeb e o Indicador de Nível Socioeconômico (Inse) do INEP;
b) teste de técnicas que combinam várias árvores, como o Random Forest, comparadas com a árvore única;
c) implementação do protótipo (atividade bônus) com a base convertida para CSV.

## 7.7 RESPOSTA À QUESTÃO PARA REFLEXÃO

*Uma estimativa próxima da taxa real de aprovação significa necessariamente que o modelo identificou os fatores responsáveis pelo rendimento escolar?*

A resposta do grupo é **não**. O modelo aprende associações, não causas. Ele pode acertar a taxa por usar atributos que acompanham o rendimento sem produzi-lo.

Nesta base isso fica claro. A aprovação nos anos iniciais é a entrada mais útil, mas não causa a aprovação nos anos finais: as duas refletem fatores que a base não tem, como o perfil socioeconômico dos alunos, as condições da escola, o corpo docente e as políticas da rede. A rede administrativa também não é causa por si: ser municipal não reduz a aprovação, mas a rede municipal atende populações e realidades diferentes.

Além disso, como 53% das escolas estão em 100%, um modelo pode ter erro médio baixo apenas repetindo o teto, sem ter aprendido nada.

Na prática, o resultado deve ser lido como **sinal de alerta**, não como diagnóstico. Afirmar que um fator é responsável pelo rendimento exigiria estudos com desenho causal (comparações controladas e acompanhamento ao longo do tempo) e variáveis que esta base não possui.

## 8 CONSIDERAÇÕES FINAIS

O trabalho propôs uma árvore de decisão para regressão que estima a taxa de aprovação dos anos finais do Ensino Fundamental em escolas de Goiás a partir da rede, da localização, do município e das taxas das outras etapas.

A análise da base mostrou que o problema é menos sobre prever bem a média e mais sobre não errar nas poucas escolas com aprovação baixa: 53% estão em 100% e apenas 8% ficam abaixo de 95%, concentradas na rede municipal. Por isso a avaliação combina MAE, RMSE, $R^2$ e o erro nas escolas abaixo de 95%.

A principal aplicação é usar o resíduo (taxa real menos estimada) para apontar escolas que aprovam menos do que o esperado para seu perfil e priorizá-las no acompanhamento pedagógico. O resultado é um sinal de alerta, não uma explicação causal. Com dados históricos e socioeconômicos, e com a implementação do protótipo, a proposta pode ganhar precisão e utilidade prática.

## REFERÊNCIAS

BREIMAN, L. et al. **Classification and regression trees**. Belmont: Wadsworth, 1984.

FACELI, K. et al. **Inteligência artificial**: uma abordagem de aprendizado de máquina. Rio de Janeiro: LTC, 2011.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The elements of statistical learning**: data mining, inference, and prediction. 2. ed. New York: Springer, 2009.

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA (INEP). **Indicadores educacionais**: taxas de rendimento escolar. Brasília: Inep, 2025. Disponível em: https://www.gov.br/inep. Acesso em: 25 out. 2026.

RUSSELL, S.; NORVIG, P. **Inteligência artificial**: uma abordagem moderna. 4. ed. Rio de Janeiro: GEN LTC, 2022.

UNIVERSIDADE ESTADUAL DE GOIÁS (UEG). **Manual de apresentação de trabalhos acadêmicos**. Anápolis: UEG, 2022.

UNIVERSIDADE ESTADUAL DE GOIÁS (UEG). **Projeto Integrador**: Inteligência Artificial. Curso de Sistemas de Informação, 2026/2. Documento da disciplina.